

ALTERNATIVES TO RAG · 热门技术深度剖析

那些媒体宣称可以替代RAG的技术

超长上下文、Agentic Retrieval与LLM Wiki深度解析



目录 CONTENTS



01. 超长上下文 (Long Context)

媒体最热衷的“替代者”，探究其原理与局限



02. Agentic Retrieval

从被动检索到主动推理的进化，深度解析其核心架构与企业实践



03. LLM Wiki

将知识结构化，构建AI原生的知识导航系统



04. 总结与展望

对比分析三大技术，展望企业知识系统的未来趋势


PART 01

超长上下文 (Long Context)

媒体最热衷的“替代者”



传统RAG的本质：固定的流水线



01. Query

用户提出问题
发起检索请求



02. Embedding

文本向量化转换
生成语义特征



03. Search

向量数据库检索
计算余弦相似度



04. Top-k

截取相似度最高的
前K个文档片段



05. 生成答案 (Answer)

将检索到的Top-k文档作为上下文，喂给LLM生成最终回答。



在这个线性流程中，**检索逻辑是写死且固定的**。系统在运行前就已决定了搜索策略、召回数量等关键参数。而强大的大语言模型（LLM）在此过程中仅仅充当了“文本总结者”的角色，**完全被动地读取结果，不参与任何检索决策**。

超长上下文：直接“喂”整个文档库

超长上下文技术的核心逻辑非常直观：利用大模型不断扩展的“记忆容量”，直接将完整的文档库作为上下文输入，从根本上绕过传统 RAG 架构中的检索与拼接步骤。

■ 传统模式：检索 + 拼接

需要先检索关键片段、再拼接输入，容易割裂内容逻辑，丢失全局信息。

■ 超长上下文模式：全量“投喂”

打破检索限制，直接将整个知识库塞进模型，让大模型基于完整上下文进行推理。

■ 支持的海量知识库类型

- 复杂文本：产品说明书、法律合同、财务年报
- 代码与记录：完整代码仓库、数小时的会议记录

workflow 简化示意

知识库 → 检索 → 拼接 → 模型 (传统方式)

↓ 优化为 ↓

完整文档库 → 直接输入 → 模型 (超长上下文)

核心价值：从“片段理解”到“全局推理”

让大模型真正“读懂”长文档，回答更精准、逻辑更连贯

大模型长上下文窗口：理论与现实

核心洞察：大模型宣传的上下文窗口长度多为理论最大值，受注意力衰减等影响，实际有效利用率仅约25%。因此，预训练与扩展阶段的训练策略与数据投入，成为决定长文本处理能力的核心变量。



DeepSeek v3

- **预训练基础**：超95%训练(14.8T tokens)基于4K窗口完成。
- **扩展路径**：YaRN两阶段快速扩展，每阶段仅1000步微调。
→ 4K → 32K → 128K



GLM 5.1

- **预训练基础**：超95%数据基于4K窗口完成预训练。
- **扩展路径**：预训练中期设“长窗口适配”阶段，逐级增加数据量。
→ 4K→32K(1T) →128K(500B)
→200K(50B)



Kimi K2.6

- **预训练基础**：主力训练(>90%)在4K窗口，少量在8K窗口。
- **扩展路径**：后期增加专门适配阶段，数据量较少。
- **核心技术**：YaRN + MLA (多头注意力) 双重优化。

结论：主流模型多以4K窗口完成绝大多数预训练，通过YaRN等技术快速扩展。扩展阶段的数据量与技术适配，是拉开长文本能力差距的关键。

主流大模型预训练窗口对比

核心洞察：训练窗口的演进差异

不同大模型在预训练阶段对长上下文窗口的重视程度差异巨大。传统模型主要在小窗口（4K/8K）完成绝大部分训练，依赖后期微调适配长文本。而新一代模型如DeepSeek v4则打破常规，开创性地将绝大部分训练数据放在超大窗口（64K/1M）完成，这一架构性的差异可能是其在长文本处理上表现更优的关键原因。

总结：原生超长窗口训练正成为行业新标杆。这表明，在预训练阶段“喂饱”长上下文数据，而非仅在微调阶段做适配，是提升大模型长文本能力的核心路径。

GLM 5.1

- 预训练：>95% 数据在**4K**窗口完成。
- 特点：典型传统模式，主要依赖后期的长窗口适配技术。

Kimi K2.6

- 预训练：主力训练(>90%)在**4K**，少量在 8K。
- 特点：与GLM 5.1策略相似，仍以小窗口训练为基础。

DeepSeek v4 Flash

- 预训练：小窗口仅占**3.125%**。
- 特点：**96.875%**数据在 64K/1M 完成，真正的原生超长上下文训练。

DeepSeek v4 Pro

- 预训练：小窗口推测占比**<6%**。
- 特点：延续原生超长窗口路线，绝大部分数据在 64K/1M 训练。

超长上下文：何时能替代 RAG？

超长上下文与 RAG 并非完全对立，而是**互补关系**。在小体量、单文档场景下，它能提供更连贯的语境；但面对海量知识，RAG 仍是企业级应用的基石。



适合替代的场景

- **小型知识库**：当知识库仅几十至几百万Token（如企业制度、说明书），可直接喂给模型。
- **单文档强相关**：针对合同分析、财报研读等场景，提供完整语境避免信息割裂。
- **高精度理解**：避免Chunk切碎与Embedding失真，更适合处理表格、跨页引用及代码逻辑。



无法替代的局限

- **知识库规模受限**：百万级文档、10TB级海量知识无法一次性塞进上下文窗口。
- **成本指数级上升**：Token消耗随上下文长度大幅增加，企业规模化应用难以承受。
- **注意力衰减**：模型存在“中间遗忘”效应，无法稳定、均匀地利用超长文本中的所有信息。


PART 02

Agentic Retrieval

从被动检索到主动推理的进化



传统RAG的本质：固定的流水线



01. Query

用户提出问题
发起检索请求



02. Embedding

文本向量化转换
生成语义特征



03. Search

向量数据库检索
计算余弦相似度



04. Top-k

截取相似度最高的
前K个文档片段



05. 生成答案 (Answer)

将检索到的Top-k文档作为上下文，喂给LLM生成最终回答。




在这个线性流程中，**检索逻辑是写死且固定的**。系统在运行前就已决定了搜索策略、召回数量等关键参数。而强大的大语言模型（LLM）在此过程中仅仅充当了“文本总结者”的角色，**完全被动地读取结果，不参与任何检索决策**。

Agentic Retrieval的本质：自主的推理过程

在 Agentic Retrieval 范式中，LLM 不再是被动的检索工具，而是成为了整个流程的主导者，它通过自主决策驱动检索：

- **搜什么 (What to search)**：基于意图理解，将模糊的问题转化为精准的搜索指令。
- **何时搜 (When to search)**：自主判断是否具备回答问题的充足背景知识。
- **下一步搜什么 (Next search)**：根据已有信息的缺口，动态规划后续的搜索路径。
- **停止或迭代 (Termination/Iteration)**：评估信息是否足够支撑结论，或判断是否存在矛盾，决定继续搜索或终止。



核心转变：
Retrieval becomes Reasoning

核心架构变化：从单次检索到循环推理

传统 RAG 架构：Retrieve Once

一个简单的线性流程，缺乏对复杂问题的探索能力：

Query → Retrieve → Generate Answer

“输入即检索，检索即回答”

Agentic Retrieval: Reason-Retrieve Loop

- ① Reason 推理：LLM深度分析问题，拆解任务并规划下一步行动。
- ② Retrieve 检索：基于推理结果，精准调用工具执行检索或计算。
- ③ Observe & Decide 观察与决策：评估结果，判断信息是否足够或是否需要继续探索。
- ④ Repeat 循环：在满足终止条件前，持续循环上述过程以逼近真相。

这是从“一次性”到“持续性”的本质进化

经典实现：ReAct Pattern

几乎所有 Agentic Retrieval 的底层逻辑，都能看到 ReAct 的影子。它是一种让 LLM 模拟人类思维方式，通过交替进行“**推理 (Reason)**”与“**行动 (Act)**”来逐步拆解、解决复杂问题的核心范式。



Thought · 思考

基于历史记忆与当前任务，推理分析下一步该执行什么操作来获取关键信息。




Action · 行动

执行具体的工具调用（如网络搜索、数据库查询或代码运行）以获取外部反馈。



Observation · 观察

获取并理解行动的结果，将其作为新的上下文输入，为下一轮思考提供依据。



核心循环逻辑

这三步构成一个闭环，不断重复迭代。直到模型通过“观察”确认已获取足够信息，能够得出可靠结论时，循环才会终止。

ReAct模式企业案例：追踪退款率升高原因



用户问：为什么退款率最近升高？



Step 1: Thought (思考)

LLM 推理假设：退款率升高可能与支付接口失败、APP新版本上线或近期客服策略调整有关。



Step 2: Action (行动)

调用日志分析工具进行验证：
``{"tool": "search_logs", "query": "退款失败 最近7天"}``



Step 3: Observation (观察)

系统返回结果：
发现第三方支付宝接口的调用失败率异常上升。



Step 4: 继续思考 (Thought)

基于失败数据，判断需进一步排查：支付系统是否在近期有代码更新或配置变更？



Step 5: 再次行动 (Action)

调用版本管理工具：
``{"tool": "search_release_notes", "query": "支付系统 最近更新"}``

最终，Agent 通过“思考-行动-观察”的自主循环，精准锁定了系统更新导致的支付接口异常根源。

技术实现：五层架构

01

Tool Layer
工具层

Agent可调用的各种检索工具，连接外部知识库与数据资源的基础接口。

02

Planner
规划器

Agent的“大脑”，基于用户需求与当前状态，拆解任务并决定下一步行动。

03

Memory
记忆层

记录Agent的历史行为、对话上下文和已知信息，赋予系统长程推理的连续性。

04

Reasoning Loop
推理循环

执行“思考-行动-观察”的核心逻辑，动态调整策略以解决复杂的检索与推理问题。

05

Execution Runtime
执行运行时

承载Agent全链路工作流的底层调度框架，确保各个模块高效协同与并行处理。

五层架构详解 (I): 工具层与规划器



01 / Tool Layer (工具层)

Agent 的“手脚”与“感官”，提供底层交互能力，是连接数字资产与智能体的桥梁。

常见能力：向量检索 · 关键词搜索 · 数据库查询 · 知识图谱 · API接口



02 / Planner (规划器)

核心任务：基于需求与信息，推理决策“下一步调用哪个工具”。

实现方式：初级：LLM Prompt 驱动；进阶：独立规划模型与搜索策略。

五层架构详解 (II): 记忆层与推理循环

03 / Memory (记忆层)

Agent需要记忆来避免重复劳动、保持上下文连贯性，是处理复杂长任务的基石。

核心记录内容:

- 已搜索查询 / 已访问页面 | • 已知事实 / 提出的假设

类比: 就像侦探的调查笔记, 记录每一步线索与发现。

04 / Reasoning Loop (推理循环)

系统的“核心引擎”，驱动 Agent 不断自我迭代解决问题。

while not solved: Think → Act → Observe

企业级增强机制:

1. 最大步数限制 (避免无限循环)
2. 置信度阈值 (证据是否足够)
3. 自我反思 (Reflection) (判断当前路径是否正确)

五层架构详解 (III): 执行运行时

05 / Execution Runtime

在真实的企业级智能体系统中，Agent 已超越简单的单次函数调用，它的运行、调度与状态维护，都需要专门的运行时框架来提供坚实的底层支撑。

核心：为什么需要 Runtime?

因为 Agent 本质上是一个**长生命周期的复杂工作流**，而非一次性的指令执行。没有运行时框架，就难以处理多步推理、状态记忆与协作问题。

热门可视化 Runtime 框架

LangGraph

构建有状态、可循环执行的 Agent 图结构工作流

AutoGen

支持多智能体间的对话协作与复杂任务分工

更多框架与基础设施能力

- ◆ CrewAI: 聚焦于角色扮演与任务协作的多智能体平台
- ◆ OpenAI Agents SDK: 安全执行环境 + 工具调用 + 多角色协作的生产场景

状态管理 · 并发控制 · 错误处理 · 任务编排 · 上下文持久化

PART 03

LLM Wiki

构建AI原生的知识导航系统



LLM Wiki: 从“切碎知识”到“保留结构”

传统RAG最大的痛点是将知识强制“碎片化”，导致上下文断裂、逻辑关系丢失。LLM Wiki的核心思想是保留知识的原始结构，为LLM构建一个可阅读、可导航的完整知识空间。

- **页面化 (Paged Structure)**: 拒绝盲目的切块，以页面为单位保持知识的完整语义与逻辑上下文。
- **双向链接 (Bi-directional Links)**: 构建实体间的关联网络，支持LLM像人类一样在知识间自由跳转与探索。
- **结构化目录 (Hierarchy)**: 建立层级清晰的目录体系，让海量的企业知识不再是一盘散沙，结构分明。
- **智能摘要与索引**: 自动生成页面摘要与关键索引，大幅提升LLM的信息定位与快速理解效率。

WHAT IS IT ? 它是什么？

LLM Wiki 是为大模型量身打造的企业级知识体系。它就像为LLM专门重构的 Confluence 或 Wikipedia，将分散的文档转化为适合机器阅读、引用与推理的结构化“百科全书”。

核心价值：告别“碎片化失忆”

**Structured Knowledge >
Fragments**

让LLM在完整的知识图谱中进行推理

工作模式对比：RAG vs. LLM Wiki



传统 RAG：“搜索-回答”模式

基于向量相似度匹配的单点检索，缺乏对复杂知识网络的探索能力，容易丢失深层逻辑关联。

Query → Embedding → Top-k Chunk →
Answer

“检索即终点，线性匹配结果”



LLM Wiki：“导航-探索”模式

核心流程：Query → 定位知识入口页 → Agent逐步导航
→ 扩展关联页面 → 生成答案

核心逻辑：Agent 模拟人类浏览维基百科的行为，从单一知识节点出发，主动点击链接探索关联领域，在持续的“导航-扩展”中构建完整的知识图景，最终基于系统化的知识网络生成答案。

从“单点碎片化”到“网络系统化”的回答能力跃迁

一：页面化 (Page-based Knowledge)



传统RAG的问题

- **切分缺陷**：将PDF/文档切成固定大小Chunk，丢失页面身份。
- **核心问题**：无主题边界、语义不完整，无法识别Chunk归属。

示例：“退款规则”被切分为
Chunk_182 (上半段) + Chunk_183 (下半段)
→ LLM无法识别二者属于同一主题



页面化的实现流程

Step 1: 文档解析

提取标题、段落、表格，保留原始结构。

Step 2: 结构识别

识别Markdown层级，构建父子关系树。

Step 3: 生成Page Object

封装page_id/title/content/summary结构化对象。

从“无边界Chunk”到“结构化Page”的知识重构

二、双向链接 (Bi-directional Links): 知识互联的关键

核心价值：打破知识孤岛

借鉴维基百科的链接思想，让孤立的文本片段形成相互关联的网络。这对RAG系统至关重要，能帮助模型自动扩展关联知识，突破传统Top-k检索仅返回“直接匹配”结果的局限。

典型关联示例：

退款规则 ↔ 财务审批 ↔ 发票制度 ↔ 税务政策



Step 1: NER

识别文本中的关键实体
如“OpenAI, API Key”



Step 2: 链接

检查实体是否存在
生成 [[API Key]] 链接



Step 3: 反向索引

自动维护索引
记录谁引用了当前页面



技术选型

简单版: 向量相似度
进阶版: 知识图谱 (KG)



反向索引数据结构示例

```
{"API Key": ["OpenAI API文档", "系统权限管理规范", "API鉴权机制说明"]}
```



通过双向链接构建的“**非结构化知识图谱**”，RAG系统不仅能“召回”直接相关的文本，更能基于链接关系进行“**多跳推理**”和**关联扩展**，从而显著提升回答的丰富度和准确性。

三、层级目录 (Hierarchy Tree)

让 LLM 理解知识结构与上下文

模拟人类查阅书籍的方式，引导LLM先定位大类再聚焦细节，解决“大海捞针”式检索。**核心优势：模拟人类认知逻辑 · 大幅提升检索精准度与效率**

目录结构示例

```
graph TD
    A[财务制度] --- B[报销制度]
    A --- C[差旅报销]
    A --- D[餐饮报销]
    A --- E[发票制度与合规]
```

层级结构实现方式

1. 文档原生解析

直接解析 Markdown 标题层级 (#, ##)，构建抽象语法树 (AST Tree)，还原作者意图。

2. LLM 自动生成

针对无结构化文本，通过 Prompt 指令让模型分析内容逻辑，输出JSON格式的层级关系。

企业级存储与应用能力

通常存储为节点关系型数据库，通过父子ID关联维护层级：

```
{ "node_id": "1001", "parent_id": "1000", "children": [...] }
```

支持：树遍历 (Traversal) · 层级检索 · 章节动态扩展

四、实体关系 (Entity Relationship)

实体关系抽取是构建知识图谱 (LLM Wiki) 的核心能力，其本质是从非结构化文本中，自动识别并抽取出结构化的“实体”与“关系”，为AI提供可计算的骨架。

■ 结构化抽取示例

原文：“张三负责 Apollo 项目。Apollo 项目服务于腾讯。”

结果：(张三, 负责, Apollo)、(Apollo, 客户, 腾讯)

■ 为何这是关键？

将信息转化为实体与关系后，才能打破文本孤岛，实现复杂的**多跳推理**，让 AI 具备像人一样理解、关联和运用知识的能力。

主流实现方法

- 1.LLM 端到端抽取 (主流):通过精心设计的 Prompt 指令，直接让大模型输出结构化数据，高效且适配性强。
- 2.传统 NLP 技术栈:利用依存句法分析、NER等工具，目前在追求极致效率场景仍有应用，但正逐步被 LLM 方案替代。

存储与最终形态

抽取结果通常存入图数据库 (Graph DB) (如 Neo4j)，将海量碎片化信息编织成一张可被高效查询、遍历和推理的知识图谱 (Knowledge Graph)，为企业构建专属的数字大脑。

五、自动摘要 (Auto Summary)

为什么需要？ 企业知识通常篇幅过长，大语言模型 (LLM) 难以每次读取全文。因此，需要高效的摘要技术提炼核心信息，解决长上下文处理难题。



1. Chunk Summary (细粒度摘要)

对长文本的最小语义单元 (Chunk) 进行初步提炼，保留关键事实与数据。



2. Page Summary (页面聚合摘要)

将分散的 Chunk 摘要进行聚合与逻辑整合，生成完整的页面级摘要。



3. Section Summary (全文/章节摘要)

进一步聚合页面摘要，形成文档全貌的宏观摘要，输出关键结论与核心观点。

高级玩法: Query-aware Summary

核心思想：从“为文档生成通用摘要”转变为“为用户问题动态提取答案”，精准匹配信息需求。

技术演进：这已接近 Agentic Retrieval 的核心逻辑，即根据用户意图动态调整信息处理路径，是 RAG 的重要升级方向。

示例结构: {page:..., summary_short:..., key_points: [...]}

六、自动索引 (Auto Indexing)

本质：为知识建立多种访问入口

自动索引的核心思想是为知识建立多样化的访问入口，打破单一向量 (Embedding) 检索的局限，通过组合不同维度的检索能力来覆盖复杂的查询需求。

当前主流：混合搜索 (Hybrid Search)

现代企业级系统普遍采用混合策略以达到最佳效果，其核心组合是：
BM25 (关键词) + Vector (语义) + Graph (关联)

企业真实系统中的索引类型

- **Vector**: 理解文本深层语义含义
- **BM25**: 经典高效的关键词检索
- **Entity**: 人名/产品名等精准匹配
- **Graph**: 探索实体关联与多跳检索
- **Hierarchy**: 支持目录式层级导航
- **Temporal**: 基于时间维度的过滤
- **Permission**: 精细化的数据权限控制


常见技术栈选型

Elasticsearch / OpenSearch: 成熟的搜索引擎，支持 BM25 与向量检索的混合查询。

Weaviate / Milvus: 专为 AI 构建的向量数据库，提供高性能的海量向量存储与检索。

Vespa: 支持混合搜索的实时大数据处理引擎，适合低延迟场景。

七、Semantic Navigation（语义导航）




本质：从“召回”到“导航”

不再是简单的 top-k 召回，而是 LLM 像人一样，自主决定下一步该去哪里探索。

类比：如在维基百科上阅读，不断点击链接，从一个知识点跳转至另一个。

示例 (用户问“退款失败为何增多?”)：1.退款规则 → 2.支付系统 → 3.版本更新 → 4.Bug报告 → 5.客服工单



实现：Retrieval as Agent Action

核心流程：reason → retrieve → read → decide next retrieve

常见架构：• ReAct (思考→行动→观察循环) • Tree Search (在知识图谱上进行BFS/MCTS导航)

本质区别：传统RAG中检索是“系统行为”，而语义导航中检索是“模型自主行为”。

LLM Wiki 的三层架构：从数据到智能

Karpathy提出的LLM Wiki三层架构，将企业知识系统从简单的“存文档”升级为类似“编译器”的智能系统，实现了从原始数据到结构化知识的质变，是AI时代构建企业知识库的新思路。



Raw Layer (原始数据湖)

事实来源 (Source of Truth): 包含文档 (PDF/Word)、代码 (Git)、数据库、IM记录等所有原始、未加工数据。

- 特点：数据混乱、不可控，不适合直接处理。
- 价值：保留原始事实，为回溯提供依据。



Wiki Layer (编译输出层)

核心知识层: AI“编译”后的结构化知识，含页面、摘要、实体、双向链接及关系图等。

- 本质：“知识编译器”
- 价值：将原始数据转化为LLM可高效利用的预编译知识。



Schema Layer (控制协议)

系统规则层: 定义知识宇宙的操作规范，包括页面模版、实体Schema、命名规范、链接规则等。

- 价值：统一知识表示，避免实体不统一、命名混乱，确保系统长期可维护。

核心转变：从 Query-time Intelligence (查询时理解) 转向 Ingest-time Intelligence (摄入时编译)。这一架构的本质，是将“企业知识库”升级为“AI时代的知识编译系统”。

LLM Wiki: 知识的持续演化

核心区别：从“新增”到“重构”

企业知识系统的最大挑战在于应对知识的持续演化。传统RAG系统将新知识仅作为“素材”进行简单的叠加，无法更新知识间的深层关联。而LLM Wiki将知识视为动态系统，在每次更新时进行整体的“编译”与“重构”，以确保知识网络的准确性与实时性。

传统 RAG (Append-only)

新文档 → 切分 → 向量化 → 入库
本质：仅新增搜索素材，不会更新摘要、实体关系等深层结构。知识是孤立、静态的。

LLM Wiki (Recompilation)

新知识 → 解析 → 重构 → 全局更新
本质：类似代码的“增量编译”。新知识进入后，整个知识空间的实体、关系和摘要都可能发生连锁变化。

■ 企业级LLM Wiki的完整知识更新流水线

1. 变更检测(Change Detection) → 2. 文档解析(Document Parsing) → 3. 实体抽取(Entity Extraction) → 4. 关联分析(Link Analysis) → 5. 页面更新(Page Update) → 6. 摘要重建(Summary Rebuild) → 7. 图谱更新(Graph Update) → 8. 索引刷新(Index Refresh) → 9. 一致性检查(Consistency Check)

LLM Wiki: 知识更新的触发机制

LLM Wiki 的知识更新不再是人工维护的静态过程，而是由“**外部业务事件**”与“**内部逻辑规则**”双轮驱动的动态进化体系，实现了知识的自我生长与持续迭代。



主动触发：外部事件驱动

- 原始数据变更：合同版本迭代、产品手册更新、CRM/DB新增记录等源头变化直接同步。
- Schema / 规则迭代带来的批量更新：当你修改了 Schema Layer 的规则时，会触发全量 / 增量的知识重编译。
- 核心价值：确保知识库与业务现实世界保持毫秒级同步，奠定准确性基础。



被动触发：内部逻辑驱动

- 连锁反应：客户/产品属性变更时，自动重构所有关联文档与知识图谱关系。
- 外部知识源的自动同步：企业系统对接的外部数据源发生变化，会自动同步为新知识。
- 业务流程产出：项目立项文档、跨部门会议纪要、合规审计报告等协作交付物自动纳入。

LLM Wiki：现实挑战与本质总结

现实落地的五大核心挑战

工程化落地面临级联更新成本高、知识生成不一致、实体命名混乱、关系链接过量及摘要失效等系统性难题，是系统设计必须解决的拦路虎。

本质：知识定义的范式跃迁

传统RAG视知识为“被动存储”，系统更像“搜索工具”；而LLM Wiki视知识为“持续演化的动态系统”，旨在构建一个“可进化的知识操作系统”。

关键技术难点解析

成本与震荡：级联更新成本极高；LLM生成内容容易产生时间不一致性。

实体与链接：同一实体多命名导致漂移；自动链接引发海量关系难以管理。

摘要级联效应：底层摘要的微小变化可导致上层摘要体系全部失效。

打造真正的企业知识大脑

从“静态检索”转向“动态生长”，解决知识孤岛与更新滞后问题。通过动态演化机制，构建一个可维护、自适应、持续进化的智能知识底座。

核心目标：让企业知识从“死数据”变为“活系统”

LLM Wiki的现实挑战

尽管LLM Wiki能有效整合知识，但在构建与维护的过程中，我们面临着以下三大核心挑战：



构建成本高

相比传统RAG“扔文档进去即可”的简单模式，LLM Wiki需要复杂的工程处理，包括文档解析、页面拆分、实体提取、链接生成、图谱构建等，对技术团队要求较高。



知识更新更难

Wiki化后，知识之间存在复杂的关系依赖。更新其中一部分内容时，可能导致关联的摘要、内部链接或知识图谱失效，日常维护成本显著高于普通知识库。



不适合超实时数据

对于高频变化的股票交易数据、IoT实时流数据、系统实时日志等超实时数据场景，直接使用专业的时序数据库或实时查询工具，在效率上远优于LLM Wiki。

技术选型指南：适合「超长上下文」的场景

核心选型逻辑

适用特征：一次性处理 · 单文档为主 · 低更新频率
核心诉求：追求“读全量原文”，拒绝碎片化理解

法律/合同/审计文档深度审阅

场景：一次性审核数十页的合同条款、财务审计报告，需逐字核对风险。
优势：无需复杂检索系统，全文直喂模型，开发落地成本最低。

代码文件/PR 完整逻辑 Review

场景：一次性审阅大型函数、复杂配置或完整代码提交(PR)逻辑。
优势：避免因Chunk拆分导致逻辑断裂，完美适配“一次性精读”需求。

静态长文档问答

典型对象：产品说明书、历史白皮书、归档的项目总结报告等。
核心价值：一次解析，长期可用，无需搭建高频更新维护架构。

不适用场景

- 高频更新的实时动态知识库
- 海量非结构化数据的检索查询
- 对响应延迟极其敏感的交互场景

关键优势总结

- 架构极简：无需维护向量数据库
- 理解完整：无信息丢失风险
- 成本可控：显著降低开发与运维复杂度

选型金句

“读一遍、单文件、不改了”
→ 直接上 Long Context!

技术选型指南：适合「Agentic Retrieval」的场景

核心思想

摒弃简单的“一次搜索”，通过**多步推理**、**跨数据源关联**、**构建强逻辑链**，让 AI 像人一样思考并查资料，解决复杂问题。

选型速记口诀

查多步 · 跨系统 · 找根因

→ 首选 Agentic Retrieval



复杂故障排查与根因分析

【场景】退款失败时，Agent自主串联日志、支付状态、版本更新、工单记录，层层定位Bug。

【核心优势】按需动态检索，避免海量日志信息过载，精准定位问题。



跨系统/部门复杂咨询

【场景】回答客户全链路信息时，跨CRM、项目文档、合同系统、财务系统自动规划检索路径。

【核心优势】解决“多跳、多源”难题，打破信息孤岛，提供一站式完整答案。



客服疑难问题处理

【场景】处理复杂投诉时，结合客户档案、历史对话、产品知识库，生成定制化解决方案。

【核心优势】不局限于固定FAQ，能随用户追问动态调整策略，处理非标准化难题。

技术选型指南：适合「LLM Wiki」的三大核心场景

核心选型逻辑

结构化 · 强关联
持续迭代 · 长期维护

终极目标：
打造可复用的“企业级知识资产”

选型黄金口诀

如果您的文档需要
“要沉淀、强关联、常更新”

→ 首选 LLM Wiki ←



技术资产沉淀

典型场景：

Git代码仓库、PR/Issue记录、API接口文档。将它们转化为“代码实体 + 依赖关系 + 变更历史”的完整知识图谱。

核心价值：

彻底解决“为什么这么写？”、“这段代码依赖谁？”、“历史变更记录在哪里？”等长期维护难题。



产品/项目体系

典型场景：

产品需求文档、项目交付手册、技术会议纪要。构建“层级目录 + 双向链接 + 版本控制”的结构化知识库。

核心价值：

支持从接口文档直接“跳转”到关联的后端服务、业务用例及历史变更记录，打破信息孤岛。



制度与管理规范

典型场景：

财务报销制度、人事入职流程、合规政策文档等。这类文档往往高频更新，且内部条款之间存在复杂的关联关系。

核心价值：

通过实体关系链，快速回答“某条政策对应哪个流程？”、“需要填写什么表单？”、“该条款历史上修改过几次？”。